Université des Sciences et de la
Technologie Houari Boumediene

Data Mining

Rapport
Algorithme Apriori et PF-growth

Rédaction:
MOULAI Hassina Safaa
Matricule : 201400007564
HOUACINE Naila Aziza
Matricule : 201400007594
M2 SII Groupe:3

Professeur
Mme. BABA ALI

November 10, 2018

Contents

1 Généralités **2**

2 Apriori **3**
2.1 Concepts de base pour apriori 3
2.2 Principe de fonctionnement 4
2.3 Pseudo-code 5
2.4 Déroulement sur un exemple 5

3 FP-Growth **7**
3.1 Concepts de base pour FP-Growth 7
3.2 Principe de fonctionnement 8
3.3 Pseudo-code 9
3.4 Déroulement sur un exemple 11

Chapter 1

Généralités

Concepts généraux pour la détection de motifs fréquents

Quelques notion relatives à la détection de motifs fréquents doivent préalablement etre définis:

un itemset

un item set (ensemble d'items) est un ensemble comportant des items ou des éléments qui se produisent ensemble . par exemple : un itemset de transactions T=(T1=lait,café,T2=yaourt ,crème glacée,T3=couche bébé....)

le support

supp (X) d'un jeu d'éléments X est le rapport entre les transactions dans lesquelles un jeu d'éléments apparaît et le nombre total de transactions.

frequent itemset

Un ensemble d'éléments fréquent est un ensemble d'éléments dont le support est supérieure à une prise en charge minimale spécifiée par l'utilisateur (notée Lk, où k est la taille de l'ensemble d'éléments)

Chapter 2

Apriori

A priori est un algorithme fondamental proposé par R. Agrawal et R. Srikant en 1994 pour d'éléments fréquents pour les règles d'association booléennes [AS94b]. Le nom de l'algorithme est basé sur le fait que l'algorithme utilise connaissance préalable des éléments fréquents comme nous le verrons plus tard. c'est un algorithme facile à comprendre et très utilisé .

2.1 Concepts de base pour apriori

Tout d'abord avant de plonger directement dans le principe de fonctionnement globale de l'algorithme on a à définir quel que notion :

candidate itemset

Un groupe d'éléments candidat est un groupe d'éléments potentiellement fréquent (noté Ck, où k est la taille du groupe d'éléments)

Apriori propriété

chaque subset (sous-ensemble d'item) d'un fréquent itemset doit être fréquent (condition du support minimale vérifié).

Opération JOIN (jointure)

Pour trouver le L_k (frequent itemset de items), on utilise un ensemble de candidate itemset qui sont générés grâce à la jointure de L_{k-1} avec L_{k-1} (produit cartésien).

2.2 Principe de fonctionnement

Apriori emploie un approche itérative tel que chaque k-itemsets est utilisé pour explorer les (k+1)-itemsets .

les differentes étapes :

1. Exploration de la base de données pour avoir le support de chaque 1-itemset (ensemble d'un seul item).
2. Comparer le support(fréquence) avec le **min_supp** .
3. Supprimer les 1-itemsets ayant un support inférieur au **min_supp** génerer alors $L1$.
4. Faire une jointure de L_{k-1} avec L_{k-1} pour générer les ensembles de candidate k-itemsets.
5. Verifier la propriété APRIORI pour élaguer les k-itemsets qui ne sont pas fréquents.
6. Exploration de la base de données pour avoir le support de chaque candidate k-itemset vérifiant la propriété apriori.
7. Comparer le support de chaque candidate k-itemset avec **min_supp**
8. Garder que l'ensemble des k-itemsets vérifiant la condition de **min_supp** et on aura ainsi L_k
9. si L_k est vide alors pour chaque frequent itemset 1 générer les subsets non vide de 1, et pour chaque s subsets non vide de 1, ecrire la regle "s implique(1-s)" si la confidence C de la règle "s implique 1-s" satisfait le **support min de confiance**
10. sinon aller à 4

2.3 Pseudo-code

Algorithm 1 APRIORI

Input: D,base de données de transations ,support minimum
Output: L, itemset fréquent dans D

```
1 L1= find frequent 1-itemsets(D);
2 for k ← 2; L_{k-1}! = ∅; k++ do
3     C_k ← apriori_gen(L_{k-1})
4     for transaction t ∈ D do
5         scan D for counts
          C_t=subset(C_k,t); génerer les subsets de t qui sont candidats
6         for candidate c ∈ C_t do
7         c.count++;
8         L_k= c ∈ C_k , c.count>support minimum
9 return L = ⋃_k L_k
```

2.4 Déroulement sur un exemple

Nous prenons comme exemple applicatif les données de transaction d'un entreprise.
Nous y appliquons l'algorithme apriori pour retrouver les motifs fréquents, comme suit:

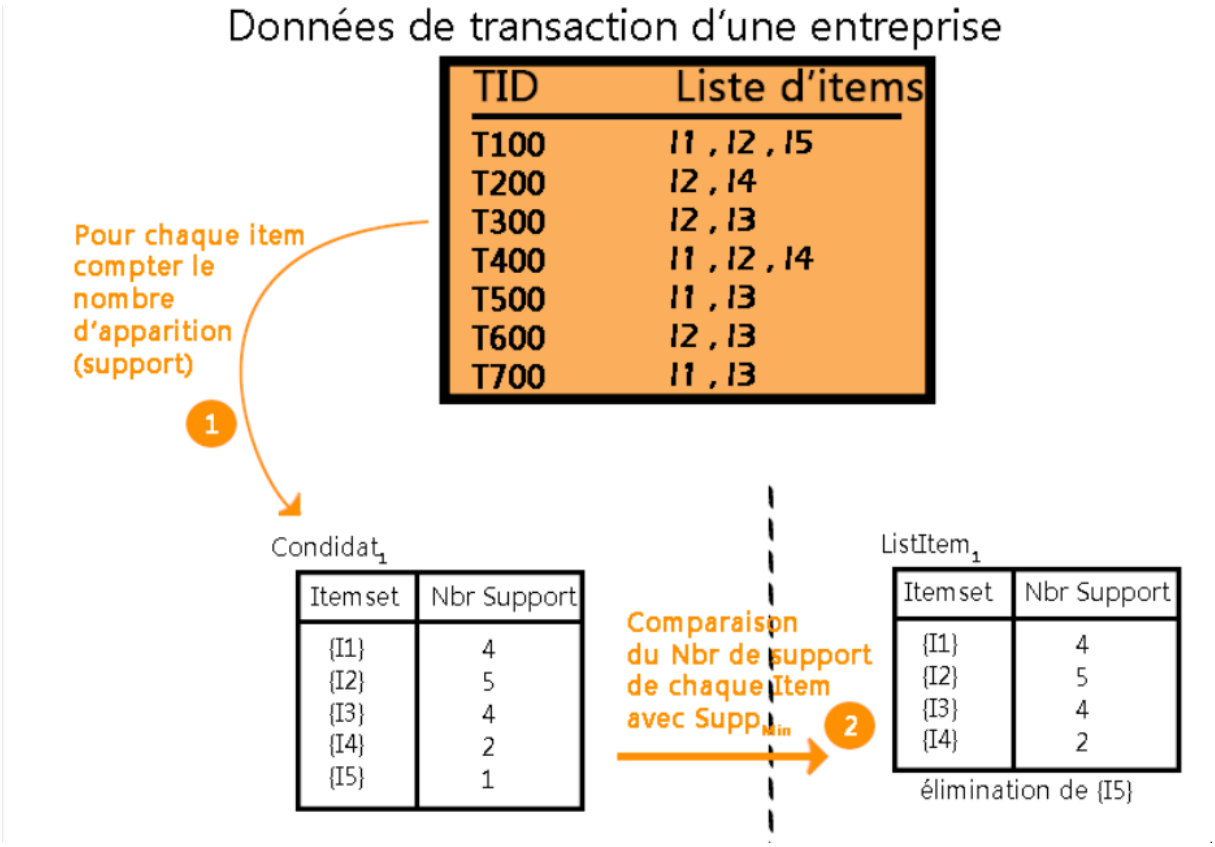

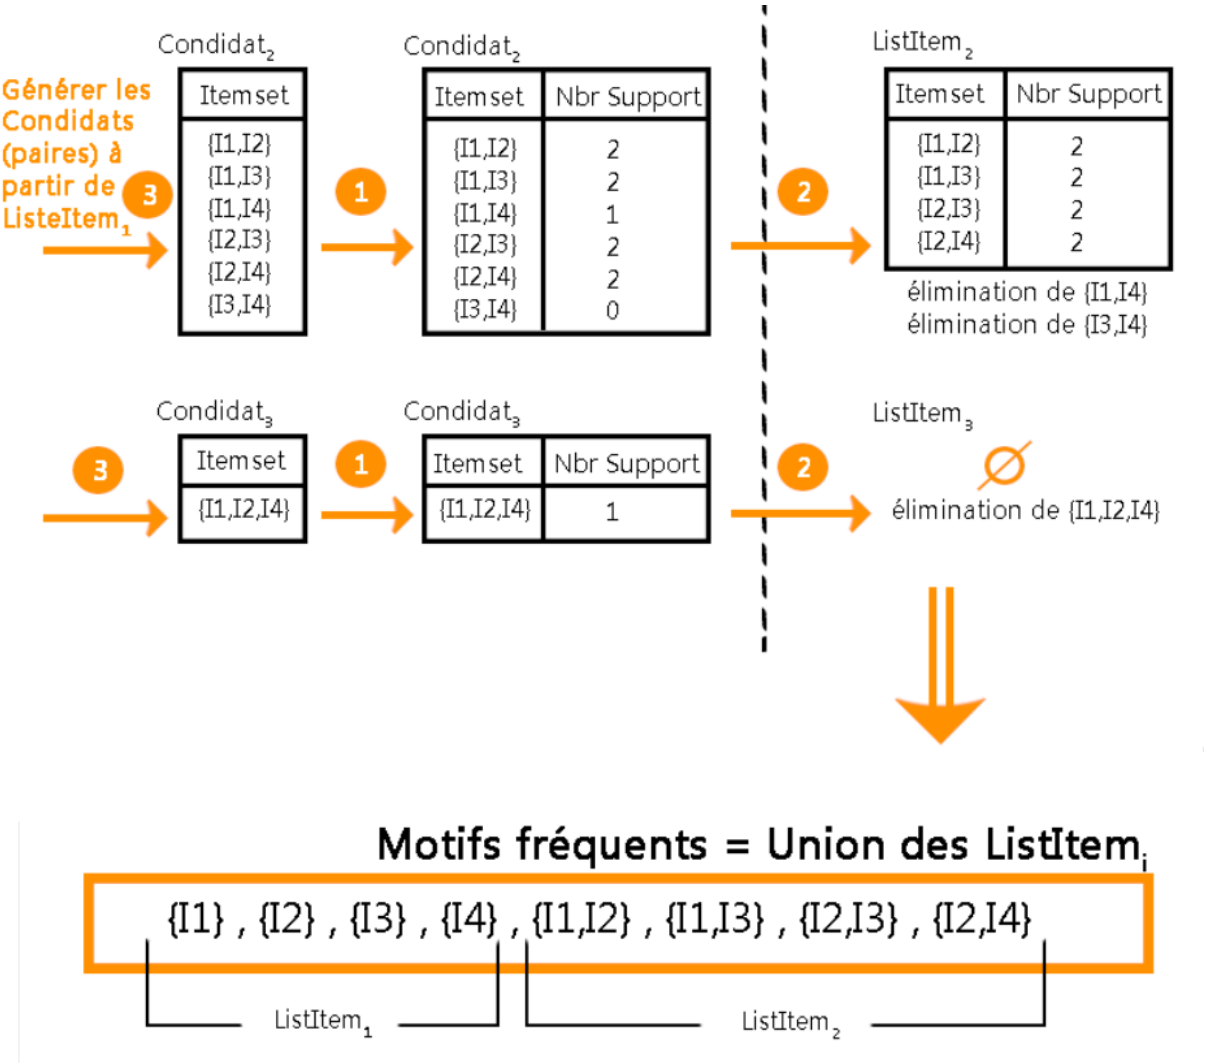

Figure 2.1: Déroulement de l'algorithme Apriori sur un exemple.

Chapter 3

FP-Growth

FP-Growth est un algorithme proposé par Han en 2000,c'est une méthode efficace et évolutive pour l'exploitation minière. Utilisation d'une structure d'arborescence de préfixes étendue pour le stockage d'informations compressées et cruciales sur les modèles fréquents nommés arborescence de modèles fréquents (FP-tree).

3.1 Concepts de base pour FP-Growth

Tout d'abord avant de plonger directement dans le principe de fonctionnement globale de l'algorithme on a à définir quel que notion :

Tree (Arbre)

Un arbre est une structure constituée de nœuds, qui peuvent avoir des enfants (qui sont des nœuds à leur tour).

Dans cet algorithme nos noeuds sont des paires (Item:freq)

Deux types de nœuds ont un statut particulier : les nœuds qui n'ont aucun enfant, qu'on appelle des feuilles, et un nœud qui n'est l'enfant d'aucun autre nœud, qu'on appelle la racine, dans notre FP-Tree c'est la racine null.

Path (Chemin)

C'est une suite de nœuds allant de la racine vers une feuille, pour cet algorithme il s'agit d'une suit d'Items constituant une transaction, ces Items sont ordonné des plus fréquents aux moins fréquents.

3.2 Principe de fonctionnement

Les différentes étapes :

1. Exploration de la base de données pour avoir le support de chaque 1-itemset (ensemble d'un seul item).
2. Comparer le support(fréquence) avec le **min_supp** .
3. Supprimer les 1-itemsets ayant un support inférieur au **min_supp** , et ordonner les autres Items dans l'ordre décroissant de nombre de support, générer alors L.
4. Initialiser notre FB_{Tree} a $null$
5. Ordonner les Item de chaque transaction selon l'ordre obtenu dans L
6. Construction de FB_{Tree} de manière itérative:

   Pour chaque Transaction insérer les items la formant dans le FB_{Tree}

   tel que soit on ajoute un nœuds (si celui si n'existe pas), soit on incrémente la fréquence du nœuds (dans le cas contraire).
7. Pour chaque Item de L toujours dans l'ordre décroissant de fréquence et en utilisant une stratégie de profondeur d'abord:

   On détermine l'arbre de cet Item (tous les chemins allant de la racine $\{\}$ a cet Item)
8. si l'on trouve un seul chemin P constitué d'un ensemble d'Items, alors on génère toutes les combinaisons β de ces Items
9. On récupère les combinaison β ayant un support $\geq$ **min_supp** que l'on ajoute a notre liste de motifs fréquents $\alpha \cup \beta$
10. Sinon (plusieurs chemins) générer les motifs de support $\geq$ **min_supp**
11. Construire la base de motif conditionnelle à partir de β
12. une fois toutes les combinaisons récupéré, on fait un appel récursif de FP-Growth avec la nouvelle liste β (retour à 8)

3.3 Pseudo-code

Algorithm 2 FP-Growth

Input: D:base de données de transations ,$Supp_{min}$:support minimum
Output: L: itemset fréquent dans D

```
10 L= find frequent 1-itemsets(D);
11 //Create the root of an FP-tree, and label it as "null."
12 FP_tree = {null}
13 foreach Trans in D do
14 |   Sort Items of (Trans) according to the order of (L)
   |   foreach Item in Trans do
15 |   |   //FP_tree is the first element
   |   |   //P is the remaining list
   |   |   Insert_tree([FP_tree|P], Item)
16 L = FP-growth-Const(FP_tree, null)
17 return L
```

Algorithm 3 Procedure Insert_tree

```
Procedure : Insert_tree([p—P], Item)
if Item.has_a_child(N) And N.item-name = p.item-name then
|   N.freq ++
end
else
|   Create_Node(N)
|   N.freq = 1
|   Link_To_Parent(Item, N)
end
if P.empty() == False then
|   insert_tree(P, N)
end
return P
```

Algorithm 4 PROCEDURE FP-GROWTH-CONST

procedure FP_growth-Const(Tree, α)
if *Tree contains a single path P* **then**
  foreach *combination β of the nodes in the path P* **do**
    generate pattern $\beta \cup \alpha$ with support_count = minimum support count of nodes in β;
else
  foreach *a_i in Q /*the header of Tree*/* **do**
    generate pattern $\beta = a_i \cup \alpha$ with support_count = a_i.support_count
    construct β conditional pattern base and then β conditional FP_tree $Tree_\beta$
    if $Tree_\beta = \emptyset$ **then**
      FP_growth($Tree_\beta$, β)
    set(Q) is the set of patterns generated
return α

3.4 Déroulement sur un exemple

Nous prenons comme exemple applicatif les données de transaction d'un entreprise.
Nous y appliquons l'algorithme FP-Growth pour retrouver les motifs fréquents, comme suit: